Disjoint Sets

Partition

En partition (dansk: disjunkt opdeling) af en mængde S er en samling ikke-tomme delmængder A_i , $i=1,\ldots,k$, som er disjunkte og tilsammen udgør S:

$$A_i
eq \emptyset$$
 for alle i
 $A_i \cap A_j = \emptyset$ for $i \neq j$
 $A_1 \cup A_2 \cup \cdots \cup A_k = S$

Eksempel:

 $\{a,b,e\}$, $\{f\}$, $\{c,d,g,h\}$ er en partition af $\{a,b,c,d,e,f,g,h\}$

Datastrukturen Disjoint Sets

Disjunkte opdeling som datastruktur? Følgende samling operationer har vist sig relevante i mange anvendelser (herunder nogle senere i kurset):

```
Make-Set(x):
```

Opret $\{x\}$ som en ny mængde (x må ikke være element i andre mængder).

Union(x, y):

Slå
$$\{a, b, c, ..., x\}$$
 og $\{h, i, j, ..., y\}$ sammen til $\{a, b, c, ..., x, h, i, j, ..., y\}$.

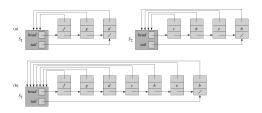
FIND-SET(x):

Returner (en ID for) mængden indeholdende x.

NB: Vi har ingen krav til ID for mængder. Den skal blot være ens for alle x i samme mængde, således at vi kan checke om to elementer x og y ligger i samme mængde.

Disjoint Sets implementeret via lænkede lister

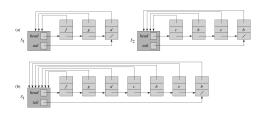
Hver mængde er en lænket liste af elementer, ID for mængde er første element i listen:



- FIND-SET(x): returner (via header-pointer) første element i listen.
- ▶ MAKE-SET(x): opret ny liste.
- ▶ UNION(x, y): slå lister sammen, behold én header, ændrer alle header-pointere i den anden liste.

Disjoint Sets implementeret via lænkede lister

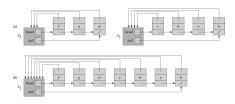
Køretid (n er antal elementer, dvs. antal MAKE-SETs udført)?



- ► FIND-SET(x): returner (via header-pointer) første element i listen: O(1).
- ▶ MAKE-SET(x): opret ny liste: O(1).
- UNION(x, y): slå lister sammen, behold én header, ændre alle header-pointere i den anden liste: O(n).

Naiv analyse: n MAKE-SET, op til n-1 UNION, og m FIND-SET koster $O(m+n^2)$.

Disjoint Sets implementeret via lænkede lister, version 2



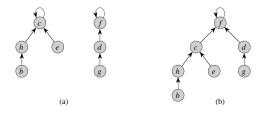
- FIND-SET(x): returner (via header-pointer) første element i listen: O(1).
- ▶ Make-Set(x): opret ny liste: O(1).
- ▶ UNION(x, y): slå lister sammen, behold header af længste liste, ændre alle header-pointere i korteste liste: O(n).

Observér at nu gælder: en knude kan kun ændre sin header-pointer $\log n$ gange, da størrelsen af dens mængde hver gang vokser mindst en faktor to $(1 \cdot 2^k \le n \Leftrightarrow k \le \log n)$.

Så bedre analyse: n MAKE-SET, op til n-1 UNION, og m FIND-SET koster $O(m+n\log n)$.

Disjoint Sets implementeret via træer

Hver mængde er et træ med elementer i knuder, rod er ID for mængde:

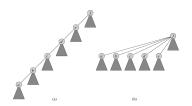


- ► FIND-SET(x): gå til rod.
- ▶ MAKE-SET(x): opret nyt træ.
- ▶ UNION(x, y): gør rod af ét træ til barn af andet træ.

Disjoint Sets implementeret via træer, version 2

Union by rank: Tilføj et heltal (rank) til alle rødder. Sættes til 0 ved nye træer (under Make-Set(x)). Kontrollerer forældre-barn beslutningen ved Union(x,y): rod med størst rank får den anden rod som barn. Ved ens rank, lad y få x som barn og øg y's rank med 1.

Path compression: Under FIND-SET(x), sæt alle passerede knuder op som børn af roden. For FIND-SET(a):



Union by rank og path compression \Rightarrow meget tæt på O(m+n) tid. Mere præcist $O(m \cdot \alpha(n) + n)$, hvor $\alpha(n)$ er en meget langsomt voksende funktion.

Funktionen $\alpha(n)$ samt beviset for køretiden findes i afsnit 19.4, som ikke er pensum (gennemgås i et senere kursus på datalogistudiet).

Disjoint Sets implementeret via træer, version 2

Pseudokode (med union by rank og path compression) er forbavsende simpel:

```
MAKE-SET(x)
                         UNION(x, y)
                          LINK(FIND-SET(x), FIND-SET(y))
  x.p = x
  x.rank = 0
                FIND-SET(x)
                  if x \neq x.p
                      x.p = \text{FIND-Set}(x.p)
                  return x.p
Link(x, y)
 if x.rank > y.rank
     y.p = x
 else x.p = y
     // If equal ranks, choose y as parent and increment its rank.
     if x.rank == y.rank
         v.rank = v.rank + 1
```